

서울시 공공자전거(따릉이) 이용 행태 및 수요 예측 모델링

기상 요인과 상권 특성의 Interaction 및 Non-linear Analysis를 중심으로

컴퓨터공학과 22100757 이규한

1. 분석할 데이터에 대해 설명하고, 해당 데이터 분석의 목적을 서술하시오.

활용한 데이터셋은 서울시 공공자전거(따릉이) 이용 내역 데이터, 기상청 기상 데이터(기온, 강수량, 미세먼지 농도), 그리고 캘린더 특성(주말, 공휴일, 대학 시험기간 여부)을 전처리하여 구축한 '일별 상권별 따릉이 이용 종합 데이터셋'임.

원천 데이터셋

- 1. 서울시 공공자전거 대여소별 대여/반납 승객수 정보(2026.03.01 ~ 2026.05.15): [\[서울열린데이터광장\]](#)
- 2. 서울시 공공자전거 대여소 마스터 정보 (위도/경도 및 주소 매핑용): [\[서울열린데이터광장\]](#)
- 3. 기상청 종관기상관측 (ASOS) 데이터 (서울시 기온, 강수량, 바람, 습도 등 2026.03.01 ~ 2026.05.21): [\[기상청 기상자료개방포털\]](#)
- 4. 기상청 황사관측 (PM10) 데이터 (서울시 미세먼지 농도 2026.03.01 ~ 2026.05.21): [\[기상청 기상자료개방포털\]](#)

위 데이터를 서울시의 세 가지 대표적인 입지적 특징을 지닌 주요 상권(대여소 그룹)을 기준으로 분류:

Office (오피스 상권): 여의도역, 광화문 등 직장인 통근 수요가 밀집된 지역

Leisure (여가 상권): 독섬유원지, 망원 한강공원 등 주말 및 나들이 수요가 집중되는 한강 변 지역

University (대학 상권): 주요 대학이 인근으로 학생들의 통학 및 생활 이동 수요가 높은 지역

Predictors / Response Variable:

- date:** 관측 일자 (2026년 3월 1일 ~ 5월 21일 봄철 기간)
- station_type** (Categorical Predictor): 상권 유형 (**Office, Leisure, University**)
- rentals** (Response Variable): 일별 해당 상권 대여소 그룹의 총 대여 건수
- temp** (Numerical Predictor): 일평균 기온 (°C)
- precip** (Numerical Predictor): 일강수량 (mm)
- pm10** (Numerical Predictor): 일평균 미세먼지 농도 (PM10)
- is_weekend** (Binary Predictor): 주말 여부 (주말 및 대체 휴일 = 1, 평일 = 0)
- is_holiday** (Binary Predictor): 법정 공휴일 여부 (어린이날, 근로자의 날 등 = 1, 평일 = 0)
- is_exam** (Binary Predictor): 대학 중간/기말 시험기간 여부 (4월 중순 등 = 1, 평소 = 0)

데이터 분석의 목적

기상 요인(temp, precip, pm10)과 사회적/공간적 요인(station_type, is_weekend, is_exam, is_holiday)이 따릉이 수요에 미치는 영향력을 분석하고, 예측 성능이 최적화된 통계 모델을 구축하기 위함

1. Interaction Effects 검증: 상권 유형(station_type)이라는 공간적 변수와 주말 여부(is_weekend)라는 시간적 변수의 결합 효과가 대여량에 미치는 Interaction을 Multiple Linear Regression을 이용해 분석

2. Non-linear Relationship Modeling (Moving Beyond Linearity): 기온 및 미세먼지와 대여량 간의 Non-linear Relationship을 Polynomial Regression, Splines, LOWESS 기법으로 포착하고 일반화 예측 성능 비교

3. 모델 진단 및 시계열 보정: OLS Residuals의 Autocorrelation과 Multicollinearity를 진단하고, Lag-1 시차 변수를 도입하여 예측 오차 개선, 모델 진단(VIF, 자기상관), 분류(Logistic, KNN), 정규화(Lasso/Ridge),

차원축소 및 한강 상권 특화 분석을 병행하여 모델을 최적화


2. 위 데이터를 분석하기 위한 파이썬 코드를 작성하고 해당 코드 전체 동작에 대해 간략히 설명하시오.

데이터 전처리, Non-linear Regression, Classification 모델 학습 및 모델 검증 순으로 진행

- **전처리 및 Exploratory Data Analysis (EDA):** 시간 단위 대여 이력을 파싱해 상권별 이용 패턴을 집계하고, 평일/주말 및 상권 유형별 대여량의 분포 차이를 Boxplot으로 시각화. Predictors 간 Correlation을 Pearson Heatmap으로 파악하여 Multicollinearity 가능성을 사전 탐색하고, 최종 일별 단위로 데이터를 병합
- **Interaction Multiple Linear Regression 및 Residuals 진단:** `station_type`과 `is_weekend` 간의 Interaction Terms를 포함한 Multiple Linear Regression model을 적합. 이후 Linearity, Normality, Homoscedasticity, Outliers를 검증하기 위해 Residual Diagnostics 4대 플롯(Residuals vs Fitted, Normal Q-Q, Scale-Location, Residuals vs Leverage)을 구현하고, 기본 모델과 Interaction 모델 간의 ANOVA F-test를 수행
- **Classification 및 리샘플링 (Cross-Validation, Bootstrap):** 대여량을 이진화하여 high/low 수요를 분류하는 Logistic Regression, LDA, QDA, KNN Classifier를 학습. 5-Fold Stratified CV를 통해 일반화 성능(ROC/AUC)을 산출하고, 1,000회 복원추출 Pairs Bootstrap을 구현하여 OLS 점근 표준오차의 한계를 보정하고 Regression coefficients의 Variance를 추정
- **모델 선택 및 Regularization (Regularization & Dimension Reduction):** AIC 성능 기준에 따라 Forward/Backward Stepwise Selection 알고리즘을 구현하여 최적 변수를 선택함. Ridge(L2)와 Lasso(L1) Regression을 fit하여 패널티 계수 α 에 따른 Shrinkage Path를 시각화하고, PCR과 PLS 차원축소 Regression model을 학습하여 컴포넌트 수에 따른 예측 성능을 비교
- **Non-linear Model 적합 및 비교:** 기존 변수와 대여량 간의 Non-linear 관계를 포착하기 위해 Step Functions, B-Spline, Natural Spline, Smoothing Spline, LOWESS 모델을 적합. 5-Fold CV를 적용하여 9가지 Non-linear Regression 설계의 Out-of-sample Test RMSE를 계량적으로 비교하며, Natural Spline과 B-Spline을 가산적으로 결합한 GAM을 구성하여 Partial Dependence Plot 도출
- **시계열 진단 및 Multicollinearity 제어:** Regression Residuals의 temporal dependency를 ACF/PACF 플롯과 Durbin-Watson 검정으로 진단한 후, Lag-1 시차 변수(`rentals_lag1`)를 통제 변수로 모델에 도입하여 예측 오차를 개선하고, VIF 산출을 통해 Multicollinearity를 최종 확인 및 제어
- **여가 상권 특화 분석 (OD & Circular Trips):** Leisure 상권의 18~22시 데이터를 필터링하고 LOWESS 스무딩을 수행하여 기온/강수량에 따른 이용 행태 변화를 추정. 출발-도착 대여소 ID를 대조하여 순환 대여(Circular Trips) 여부를 라벨링하고, 비순환 경로와의 이용 시간 격차 및 기온과의 Correlation을 분석

3. 파이썬 코드를 통해 실행한 결과들을 바탕으로 데이터 분석 결과를 서술하시오.


(1) Correlation 및 Interaction 분석 결과



- **기상 요인과의 Correlation:** 기온(`temp`)과 대여량(`rentals`)은 강한 양의 Correlation(0.655)를 보이며, 강수량(`precip`)과는 강한 음의 Correlation(-0.420)가 확인됨. 미세먼지(`pm10`)는 대여량과


약한 음의 Correlation(-0.105)를 가짐. 기온과 미세먼지 간의 Correlation은 -0.044로 매우 낮아 Multicollinearity 우려가 적음.

- **Interaction 효과:** `station_type`과 `is_weekend` 간의 Interaction Terms를 포함한 Multiple Linear Regression 모델을 적합시키고 기본 OLS 모델과의 nested ANOVA 비교 검정을 수행
 - 여가 상권(**Leisure**)은 주말에 대여량이 유의미하게 크게 급증하는 강한 양(+)의 Interaction Effects가 확인된 반면, 오피스 상권(**Office**)은 평일 대비 주말 대여량이 크게 감소하는 음(-)의 Interaction Effects가 나타남. 이는 오피스 상권의 자전거 수요가 주말 통근 수요 감소로 인해 줄어드는 반면, 한강 공원 등 여가 상권은 주말 나들이 수요가 집중되기 때문일 것으로 예상.
 - ANOVA nested 모델 비교 결과, F-statistic은 7.3912, p-value는 1.3×10^{-5} 로 매우 유의하게 나타남. 이는 상권별 주말 효과의 Interaction을 반영하는 것이 모델의 설명력을 유의미하게 향상시킴을 입증함.



(2) Residuals 진단 및 분류 모델 성능 결과


Residual Diagnostics: Four Plots for OLS with Interaction



- **Residuals vs Fitted:** 잔차가 0을 중심으로 비교적 고르게 무작위 분산되어 있어 Linearity

Assumption은 대체로 만족하나, Fitted Value가 매우 큰 구간에서 잔차의 산포가 넓어지는 경향을 보여 미세한 Heteroscedasticity(이분산성)가 감지됨.

- **Normal Q-Q:** 잔차의 대다수가 45도 직선에 일치하여 Normality 가정을 만족함. 다만 양쪽 끝 꼬리 영역(Heavy Tails)에서 기상 급변 등으로 인한 극단적 아웃라이어가 일부 존재함.
- **Residuals vs Leverage:** 모든 관측치가 Cook's Distance 기준선인 0.5 및 1.0 내부에 안전하게 존재하여, Regression coefficients를 심각하게 왜곡시키는 고영향력 레버리지 아웃라이어는 존재하지 않음. (최대 레버리지: 0.1791, 평균 레버리지: 0.0482)



- **Logistic Regression Odds Ratio:** 기온이 1°C 상승할 때 자전거 대여 수요가 높을(High Demand) 확률(Odds)은 1.99배로 증가하며, 강수량이 발생할 경우 High Demand일 확률은 0.24배 (76% 감소)로 급감
- **KNN K-tuning 및 Bias-Variance Trade-off:** K를 1부터 50까지 튜닝한 결과, K=1일 때 Train Accuracy는 1.00이나 Test Accuracy는 0.45로 Overfitting 현상이 관찰됨. 반면 K=11 부근에서 Test Accuracy가 0.58로 극대화되며 Train/Test 간 격차가 최소화되어 최적의 Bias-Variance Trade-off가 형성됨.
- **5-Fold CV 일반화 분류 성능:**
 - **Logistic Regression:** Mean AUC = 0.9783 (Std = 0.0193) - 최우수 성능
 - **LDA (Linear Discriminant Analysis):** Mean AUC = 0.9651 (Std = 0.0322)
 - **QDA (Quadratic Discriminant Analysis):** Mean AUC = 0.9310 (Std = 0.0473)
 - **Naive Bayes:** Mean AUC = 0.8804 (Std = 0.0578)
 - **KNN (K=11):** Mean AUC = 0.6537 (Std = 0.0510)





클래스 경계가 비교적 Linearly 잘 분리되어 Logistic Regression과 LDA가 가장 우수하고 강건한 일반화 성능을 기록함.

(3) Bootstrap 추정 및 모델 선택 알고리즘 결과

- **Bootstrap 오차 보정:** 샘플 수가 충분하고 데이터 불균형이 없는 기온(temp) 변수는 OLS Standard Error(5.489)와 Bootstrap Standard Error(5.626)의 편차가 2.49%에 불과해 안정적으로 일치하는 반면, 봄철 3개월 중 단 6일만 1의 값을 가지는 불균형 변수인 공휴일(is_holiday) 변수의 경우, OLS Standard Error(175.7) 대비 Bootstrap Standard Error가 544.7 (209.97% 차이)로 대폭 증가함.
- **Stepwise Selection:** AIC 기준으로 변수를 선택한 결과, Forward 및 Backward Stepwise Selection 모두 동일하게 ['station_Office', 'station_University', 'temp', 'precip', 'is_holiday_num', 'temp_cube']의 6개 핵심 변수 조합으로 수렴함. 기온의 Non-linearity(temp_cube), 강수량, 공휴일, 상권 더미가 따름이 대여량의 물리적 변동을 설명하는 가장 정보력이 높은 변수임을 뜻함.
- **정규화 Regression (Lasso & Ridge):** Lasso Regression(L1)의 페널티 계수 λ 가 커짐에 따라 불필요한 노이즈 변수들의 계수를 0으로 완벽히 수축시켰으며, 기온, 상권 유형, 강수량이 강력한 예측력을 유지함. Ridge Regression(L2)은 Multicollinearity가 존재하는 디자인 행렬에서 계수의 Variance를

효과적으로 제어함.




- **Dimension Reduction (PCR vs PLS):** PCR은 Response Variable과 무관하게 Predictors의 Variance만을 고려하여 주성분을 추출하므로 3~4개의 Component가 요구된 반면, PLS는 Response Variable와의 Covariance를 극대화하는 방향으로 차원을 축소하므로 단 1~2개의 Component만으로도 동일한 수준의 최적 Test RMSE에 도달하여 더 효율적인 Dimension Reduction가 가능함.(최종 비교 RMSE: PCR = 455.80 (M=10), PLS = 455.46 (M=6))




(4) Non-linear Model 심층 비교 결과

기온(temp) 변수의 다항 회귀 ANOVA 비교 결과, 2차 다항 모델이 가장 타당한 모델로 보여짐. 또한 다양한 비선형 모델에 대해 5-Fold CV 기반 Test RMSE를 비교 산출함.

- **Polynomial & Splines:** 차수나 자유도가 높아질수록 모델의 Variance가 커져 예측력이 감소하는 Bias-Variance Trade-off가 발생함. 외삽 영역에서 B-Spline보다 Natural Spline이 더 안정적인 예측선을 유지함. Smoothing Splines는 GCV를 최소화하는 최적의 패널티 계수를 통해 매끄러운 곡선 추세를 보임.
- **Local Regression (LOWESS):** Span 0.2는 과적합으로 오차가 컸으나, Span 0.5에서 극단치에 덜 민감하면서도 안정적인 추세를 유지하여 최상의 성능을 보임.







- **단순 모형의 일반화 성능:** 데이터셋에서는 **Step Functions(925.47)**와 **Linear Regression(927.55)**이 우수한 Test RMSE를 기록. 이는 기존 단독으로 대여량을 설명할 때 관계의 패턴이 비교적 Monotonic 하여, 복잡한 고자유도 모델이 데이터의 국소적 노이즈를 학습하여 발생하는 Overfitting 경향을 억제했기 때문. 차수나 기저 함수의 자유도가 늘어날수록 모델의 Variance가 커져 예측력이 감소하는 Bias-Variance Trade-off를 보임.

(5) Residuals 시계열 보정 및 한강 여가 상권(Leisure) 분석


- **GAM Partial Dependence Plot (PDP):** GAM을 통해 다중 가산 Non-linear fit을 수행한 결과, 기온은 18도까지 급격히 대여량을 상승시키다 완만해지는 Non-linear curve를 나타냄. 특히 미세먼지(**pm10**)의 부분 영향력 곡선은 Linear model에서는 유의하지 않게 나타났던 것과 달리, 미세먼지 농도가 고농도 구간으로 진입할 때 대여량을 유의미하게 하향 곡선으로 꺾이게 만드는 Non-linear 억제 효과를 명확하게 보여줌.




- **temporal dependency 및 Lag-1 보정:** OLS 모델의 Durbin-Watson 통계량이 1.1562로 나타나 잔차 간 강한 positive Autocorrelation이 확인됨. 이에 따라 1일 Lagged variable인 **rentals_lag1**(전날 대여량)을 control variable로 모델에 투입함. 그 결과 Durbin-Watson 통계량이 1.5670으로 크게 향상되어 잔차의 Independence Assumption을 충족했으며, 5-Fold Cross-Validation 기준 Test RMSE가 442.00에서 437.28로 1.07% 개선되어 시간적 의존성 통제가 성능 향상에 기여함.



- **저녁 기온과 대여량/이용 시간의 Correlation:** 한강공원 주변 대여소의 저녁 시간대(18~22시) 데이터를 분석.
 - 기온과 저녁 대여량의 관계는 **Pearson Correlation Coefficient가 0.710으로 강한 positive Correlation**. 기온이 15°C 미만(일평균 608.1건)에서 15~20°C(933.9건), 20~25°C 구간(1069.0건)으로 상승할수록 저녁 대여량이 급증하는 양상이 확인되어, "기온이 20~25°C의 시원하고 쾌적한 날씨를 보일 때 저녁 시간대 여가 대여가 활성화된다"는 가설을 잘 설명해줌.
 - 기온과 이용 시간(**avg_duration**)의 **Correlation Coefficient는 0.367로 유의미한 수준의 positive Correlation**. 기온 상승에 따라 rentals와 avg_duration이 우상향하다가 극단적인 기상 환경에서 Saturation되는 Non-linear pattern을 LOWESS 곡선이 안정적으로 추정함.



- **강수량의 영향:** 강수량과 저녁 대여량 간 Correlation Coefficient는 -0.482로, 비가 오는 날에는 한강 주변 대여량이 약 30.3% 급감함. 반면 이용 시간과의 Correlation은 -0.052로 거의 존재하지 않아, 강수 현상이 대여 여부에는 큰 영향을 미치나 일단 대여를 결정한 이용자들의 주행 시간(**avg_duration**) 자체에는 영향이 없음을 보여줌.
- **이용 경로 및 순환 경로(Circular Trips) 특성:**
 - 여가 상권 대여 건수가 가장 많은 상위 2개 경로는 **오륜동_001_4** (3,494건) 및 **자양3동_036_1** (3,454건)로 동일 대여소에서 대여하고 반납하는 순환 경로임.
 - 한강공원 주변 대여소(**Leisure**)의 경우, 출발지와 도착지가 완전히 동일한 Circular Trips 건수가 전체 대여의 8.53% (14,610건)를 차지하며 타 상권(Office: 5.41%, University: 6.09%) 대비 유의미하게 높은 수준임.
 - 이용 시간의 경우 일반 비순환 경로는 평균 24.45분인 반면, **순환 경로는 평균 52.08분**으로 약 2.13배 길게 소요됨. 이는 한강 주변 이용자들의 상당수가 레저 및 휴식형 자전거 주행을 즐기고 있다고 예상 가능함.
 - 기온이 상승할수록 일별 대여량 중 Circular Trips가 차지하는 비율의 Correlation Coefficient가 0.298로 나타나, 기온이 따뜻하고 쾌적할수록 레저 목적의 순환 자전거 이용 비율이 늘어나는 Correlation을 보임.



4. 위 파이썬 코드에서, 수업시간에 실습한 **library code** 및 내용들이 어떻게 활용되고 반영되었는지 설명하시오.

1) 탐색적 데이터 분석

- 활용 라이브러리 및 기법: `pandas, seaborn, matplotlib.pyplot, pd.DataFrame.corr()`
- 적용 내용: `groupby` 집계와 `sns.boxplot, sns.countplot`을 활용해 상관시간대별 분포 도출. 상관계수 행렬 계산 및 히트맵 시각화를 통해 다중공선성 사전 탐색.

2) Multiple Linear Regression, Interaction 및 Residuals 진단

- 활용 라이브러리 및 기법: `statsmodels.api as sm, ISLP.models.ModelSpec (MS), statsmodels.stats.anova.anova_lm, OLSInfluence, variance_inflation_factor`
- 적용 내용: MS 객체를 활용해 질적 변수 자동 더미화 및 교호작용 항을 포함한 OLS 모델 설계. ANOVA F-검정, 레버리지 연산, Residuals 진단 4대 플롯 구현 및 VIF 산출 수행.

3) 분류 모델링 및 편향-분산 추이

- 활용 라이브러리 및 기법: `sm.Logit, sklearn.discriminant_analysis (LDA, QDA), sklearn.neighbors.KNeighborsClassifier, sklearn.metrics`
- 적용 내용: 로지스틱 회귀로 오즈비를 산출하고 다양한 분류기를 적합함. KNN의 K값 변화에 따른 Bias-Variance Trade-off 현상을 시각적으로 입증하고 ROC/AUC 성능 비교.

4) 교차검증 및 Bootstrap

- 활용 라이브러리 및 기법: `sklearn.model_selection (KFold, cross_validate), sklearn.utils.resample, ISLP.models.sklearn_sm`
- 적용 내용: 5-Fold CV를 통해 모델별 Test RMSE를 도출하고, Bootstrap 기법으로 불균형 변수에 대한 OLS 추정치의 한계를 보정.

5) 변수 선택, 정규화 및 차원 축소

- 활용 라이브러리 및 기법: `sklearn.linear_model (LassoCV, Ridge), sklearn.decomposition.PCA, sklearn.cross_decomposition.PLSRegression`
- 적용 내용: Stepwise Selection 알고리즘 구현 및 Lasso/Ridge를 통한 계수 수축 경로 재현. PCR과 PLS 모델의 차원 축소 효율성을 비교 검증.

6) 비선형 모델 확장

- 활용 라이브러리 및 기법: `pd.qcut, ISLP.transforms (BSpline, NaturalSpline), pygam.LinearGAM, statsmodels.api.nonparametric.lowess`
- 적용 내용: Step Functions, Splines, Smoothing Splines, LOWESS 등 Ch7의 비선형 함수론을 집대성하여 적합함. 일반화 가법 모형(GAM)을 구축해 독립적인 곡선 효과(PDP)를 시각화.